

강의 3

당신이 알고 싶지 않은 모든 것
LM 아키텍처엔트레이닝

CS336

타츠 H

기호 논리학

❖ 슬랙에 참여하세요!


❖ 과제가 최신 버전인지 확인하세요!

개요 및 목표

- ❖ '표준' 변압기(구현하는 것)에 대한 간략한 요약
- ❖ 대부분의 대형 LM은 무엇이 공통점인가요?
- ❖ 아키텍처/교육 과정의 일반적인 변형은 무엇입니까?

오늘의 주제: 가장 좋은 학습 방법은 직접 경험하는 것이고, 두 번째로 좋은 방법은 다른 사람의 경험에서 배우는 것입니다.

시작점: '원래' 변압기



리뷰: 표준 변압기의 선택

위치 임베딩: 사인과 코사인

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}})$$



$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$

FFN: ReLU

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Norm 유형: post-norm, LayerNorm

당신이 구현한 것 - 간단하고 현대적인 변형



차이점:

- LayerNorm은 블록 앞에 있습니다.
- 회전 위치 매립(RoPE)
- FF 레이어는 ReLU가 아닌 SwiGLU를 사용합니다.
- 선형 레이어(및 레이어 노름)에는 바이어스 (상수) 항목이 없습니다.

왜 이것을 선택했을까요?
무엇을 선택해야 할까요?

FALCON2-11B TECHNICAL REPORT

우리는 건축에 대해 어떻게 생각해야 할까?

Meta

건축물이 정말 많이 있습니다. 336년 전 이후로 작년에만

Llama Team, AI@Meta

¹A detailed contributor list can be found in the appendix of this paper.

Nemotron-4 340B Technical Report

NVIDIA

QWEN2.5 Technical Report

Qwen Team

<https://huggingface.co/Qwen>

QWEN2 TECHNICAL REPORT

Qwen Team, Alibaba Group*

InternLM2 Technical Report

Zheng Cai, Maosong Cao, Haojiang Chen, Kai Chen, Keyu Chen, Xin Chen, Xun Chen, Zehui Chen, Zhi Chen, Pei Chu, Xiaoyi Dong, Haodong Duan, Qi Fan, Zhaoye Fei, Yang Gao, Jiaye Ge, Chenya Gu, Yuzhe Gu, Tao Gui, Aijia Guo, Qipeng Guo, Gonghui He, Yingfan Hu, Ting Huang, Tao Jiang, Penglong Jiao, Zhenjiang Jin, Zhikai Lei, Jiaxing Li, Jingwen Li, Linyang Li, Shuaibin Li, Wei Li, Yining Li, Hongwei Liu, Jiangning Liu, Jiawei Hong, Kaiwen Liu, Kuikun Liu, Xiaoran Liu, Chengqi Lv, Haijun Lv, Kai Lv, Li Ma, Runyuan Ma, Zeren Ma, Wenchang Ning, Linke Ouyang, Jiantao Qiu, Yuan Qu, Fukai Shang, Yunfan Shao, Demin Song, Zifan Song, Zhihao Sui, Peng Sun, Yu Sun, Huanze Tang, Bin Wang, Guoteng Wang, Jiaqi Wang, Jiayu Wang, Rui Wang, Yudong Wang, Ziyi Wang, Xingjian Wei, Qizhen Weng, Fan Wu, Yingting Xiong, Chao Xu, Ruiliang Xu, Hang Yan, Yitong Yan, Xiaogui Yang, Haochen Ye, Huaiyan Yang, Jia Yu, Jing Yu, Yuhang Zhang, Chuyu Zhang, Li Zhang, Fan Zhang, Peng Zhang, Ruijie Zhang, Shuo Zhang, Songyang Zhang, Wenjian Zhang, Wenwei Zhang, Xingcheng Zhang, Xinyue Zhang, Hui Zhao, Qian Zhao, Xiaomeng Zhao, Fengzhe Zhou, Zaida Zhou, Jingming Zhuo, Yicheng Zou, Xipeng Qiu, Yu Qiao, Dahua Lin

Shanghai AI Laboratory
SenseTime Group
The Chinese University of Hong Kong
Fudan University
internlm@pjlab.org.cn

Phi-3 Technical Language

Microsoft

Google DeepMind

Gemma 2: Improving Open Language Models at a Practical Size

Gemma Team, Google DeepMind¹

Reka Core, Flash, and Edge: A Series of Powerful Multimodal Language Models

Aitor Ormazabal Che Zheng Cyprien de Masson d'Autume Dani Yogatama
Deyu Fu Donovan Ong Eric Chen Eugenie Lamprecht Hai Pham Isaac Ong
Kaloyan Aleksiev Lei Li Matthew Henderson Max Bain Mikel Artetxe
Nishant Relan Piotr Padlewski Qi Liu Ren Chen Samuel Phua
Yazheng Yang Yi Tay Yuqi Wang Zhongkai Zhu Zhihui Xie

2025-03-12

of a Small Language Model

ouch * Gabriel Martín Blázquez * Guilherme Penedo
iliček Agustín Piqueres Lajarin Vaibhav Srivastav
uyen Clémentine Fourrier Ben Burtenshaw
n Cyril Zakka Mathieu Morlon

2024-06-27

1d7db9

19개 이상의 새로운 고밀도 모델이 출시되었으며, 그 중 다수는 사소한 아키텍처 조정이 적용되었습니다.

(밀집 아키텍처에 대한) 데이터를 살펴보겠습니다.

다른 많은 모델(및 논문)에서 배우십시오.

AI Name	#	Year	Norm	Parallel Layer	Pre-norm	Position embedding	Activations	Stability tricks
Original transformer		2017	LayerNorm	Serial	☐	Sine	ReLU	
GPT		2018	LayerNorm	Serial	☐	Absolute	GeLU	
T5 (11B)		2019	RMSNorm	Serial	☒	Relative	ReLU	
GPT2		2019	LayerNorm	Serial	☒	Absolute	GeLU	
T5 (XXL 11B) v1.1		2020	RMSNorm	Serial	☒	Relative	GeGLU	
mT5		2020	RMSNorm	Serial	☒	Relative	GeGLU	
GPT3 (175B)		2020	LayerNorm	Serial	☒	Absolute	GeLU	
GPTJ		2021	LayerNorm	Parallel	☒	RoPE	GeLU	
LaMDA		2021			☒	Relative	GeGLU	
Anthropic LM (not claude)		2021			☒			
Gopher (280B)		2021	RMSNorm	Serial	☒	Relative	ReLU	
GPT-NeoX		2022	LayerNorm	Parallel	☒	RoPE	GeLU	
BLOOM (175B)		2022	LayerNorm	Serial	☒	Alibi	GeLU	
OPT (175B)		2022	LayerNorm	Serial	☒	Absolute	ReLU	
PaiLM (S40B)		2022	RMSNorm	Parallel	☒	RoPE	SwiGLU	Z-loss
Chinchilla		2022	RMSNorm	Serial	☒	Relative	ReLU	
Mistral (7B)		2023	RMSNorm	Serial	☒	RoPE	SwiGLU	
LLaMA2 (70B)		2023	RMSNorm	Serial	☒	RoPE	SwiGLU	
LLaMA (65B)		2023	RMSNorm	Serial	☒	RoPE	SwiGLU	
GPT4		2023			☐			
Olmoe 2		2024	RMSNorm	Serial	☐	RoPE	SwiGLU	Z-loss, QK-norm
Gemma 2 (27B)		2024	RMSNorm	Serial	☒	RoPE	GeGLU	Logit soft clipping, Pre-post norm
Nemotron-4 (340B)		2024	LayerNorm	Serial	☒	RoPE	SigReLU	
Queen 2 (72b) - same for 2.5		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Falcon 2 11B		2024	LayerNorm	Parallel	☒	RoPE	GeLU	Z-loss
Phi3 (small) - same for phi4		2024	RMSNorm	Serial	☒	RoPE	GeGLU	
Llama 3 (70B)		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Reka Flash		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Command R+		2024	LayerNorm	Parallel	☒	RoPE	SwiGLU	
OLMo		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Queen (14B)		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
DeepSeek (67B)		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Yi (34B)		2024	RMSNorm	Serial	☒	RoPE	SwiGLU	
Mistral of Experts		2024			☐			
Command A		2025	LayerNorm	Parallel	☒	Hybrid (RoPE+NoPE)	SwiGLU	
Gemma 3		2025	RMSNorm	Serial	☐	RoPE	GeGLU	Pre-post norm, QK-norm
SmolLM2 (1.7B)		2025	RMSNorm	Serial	☒	RoPE	SwiGLU	

우리는 다양한 주요 아키텍처와 하이퍼파라미터
변형에 대해 이야기해 보겠습니다.

- 이 모든 모델에는 어떤 공통점이 있나요? • 어떤 부분이 다른지
까? • 이것으로부터 무엇을
배울 수 있나요?

무엇을 다룰까요?

일반적인 아키텍처 변형

- 활성화, FFN
- 주의 변형
- 위치 임베딩

중요한(또는 중요하지 않은) 하이퍼파라미터 • `ff_dim`이

란 무엇인가요? `multi_head` dims는 항상 `model_dim`과 합산되나요? • 어휘 요소
는 몇 개인가요?

안정성 트릭

아키텍처 변형..

핵심 아키텍처 부분에 대해 생각해 보자

Aa Name	# Year	⊖ Norm	⊖ Parallel Layer	☑ Pre-norm	⊖ Position embedding	⊖ Activations
Original transformer	2017	LayerNorm	Serial	☐	Sine	ReLU
GPT	2018	LayerNorm	Serial	☐	Absolute	GeLU
T5 (11B)	2019	RMSNorm	Serial	☒	Relative	ReLU
GPT2	2019	LayerNorm	Serial	☒	Sine	GeLU
T5 (XXL 11B) v1.1	2020	RMSNorm	Serial	☒	Relative	GeGLU
mT5	2020	RMSNorm	Serial	☒	Relative	GeGLU
GPT3 (175B)	2020	LayerNorm	Serial	☒	Sine	GeLU
GPTJ	2021	LayerNorm	Parallel	☒	RoPE	GeLU
LaMDA	2021			☒	Relative	GeGLU
Gopher (280B)	2021	RMSNorm	Serial	☒	Relative	ReLU
GPT-NeoX	2022	LayerNorm	Parallel	☒	RoPE	GeLU
BLOOM (175B)	2022	LayerNorm	Serial	☒	AliBi	GeLU
OPT (175B)	2022	LayerNorm	Serial	☒	Absolute	ReLU
PaLM (540B)	2022	RMSNorm	Parallel	☒	RoPE	SwiGLU
Chinchilla	2022	RMSNorm	Serial	☒	Relative	ReLU
Mistral (7B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
LLaMA2 (70B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
LLaMA (65B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
Qwen (14B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
DeepSeek (67B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Yi (34B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU


높은 수준의 관점:

- 낮은 합의를 (사전 규범 제외)

• 'LLaMA 유사' 아키텍처에 대한
추세

사전 vs 사후 규범

(2024년에) 모두가 동의하는 한 가지



Xiong 2020의 그림

거의 모든 현대 LM은 규범 이전을 사용합니다(그러나 BERT는 규범 이후였습니다)

(다소 우스꽝스러운 예외가 하나 있습니다. OPT350M. 이것이 왜 표준에 맞지 않는지 모르겠습니다.)

Post-LN Transformer

$$\begin{aligned} x_{l,i}^{post,1} &= \text{MultiHeadAtt}(x_{l,i}^{post}, [x_{l,1}^{post}, \dots, x_{l,n}^{post}]) \\ x_{l,i}^{post,2} &= x_{l,i}^{post} + x_{l,i}^{post,1} \\ x_{l,i}^{post,3} &= \text{LayerNorm}(x_{l,i}^{post,2}) \\ x_{l,i}^{post,4} &= \text{ReLU}(x_{l,i}^{post,3} W^{1,l} + b^{1,l}) W^{2,l} + b^{2,l} \\ x_{l,i}^{post,5} &= x_{l,i}^{post,3} + x_{l,i}^{post,4} \\ x_{l+1,i}^{post} &= \text{LayerNorm}(x_{l,i}^{post,5}) \end{aligned}$$


Pre-LN Transformer

$$\begin{aligned} x_{l,i}^{pre,1} &= \text{LayerNorm}(x_{l,i}^{pre}) \\ x_{l,i}^{pre,2} &= \text{MultiHeadAtt}(x_{l,i}^{pre,1}, [x_{l,1}^{pre,1}, \dots, x_{l,n}^{pre,1}]) \\ x_{l,i}^{pre,3} &= x_{l,i}^{pre} + x_{l,i}^{pre,2} \\ x_{l,i}^{pre,4} &= \text{LayerNorm}(x_{l,i}^{pre,3}) \\ x_{l,i}^{pre,5} &= \text{ReLU}(x_{l,i}^{pre,4} W^{1,l} + b^{1,l}) W^{2,l} + b^{2,l} \\ x_{l+1,i}^{pre} &= x_{l,i}^{pre,5} + x_{l,i}^{pre,3} \end{aligned}$$


$$\text{Final LayerNorm: } x_{Final,i}^{pre} \leftarrow \text{LayerNorm}(x_{L+1,i}^{pre})$$

LayerNorm을 설정하여 주요 잔여 신호 경로(왼쪽)에 영향을 미치지 않도록 합니다.


사전 규범 대 사후 규범, 데이터




살라자르와 응우옌 2019



(a) Validation Loss (IWSLT)



(b) BLEU (IWSLT)




(a) Validation Loss on BERT

Xiong 2020의 그림


사전 vs 사후 규범, 설명이 있나요?

기울기 감쇠 [Xiong 2020]



(a) W^1 in the FFN sub-layers


그래디언트 스파이크 [Salazar와 Ngyuen]



원래 명시된 이점은 워밍업을 제거한다는 것입니다.
오늘날 - 대규모 네트워크를 위한 안정성과 더 큰 LR

새로운 것 - '더블' 규범.

잔여 스트림에 LayerNorm을 넣는 것이 나쁘다면 스트림 외부에 post-norm을 넣는 것은 어떨까요?



최근 모델: Grok, Gemma 2. Olmo 2는 비잔류 포스트 노멀 만 수행합니다.

LayerNorm 대 RMSNorm

원래 변환기: LayerNorm – 평균과 분산을 정규화합니다.

$$y = \frac{x - \mathbf{E}[x]}{\sqrt{\mathbf{Var}[x] + \epsilon}} * \gamma + \beta$$

많은 최신 LM: RMSNorm – 평균을 빼거나 편향 항목을 추가하지 않습니다.

$$= \sqrt{\| \cdot \|_2^2 + \epsilon}$$

주목할만한 모델:

GPT3/2/1, OPT, GPT-J, 블룸

주목할만한 모델:

LLaMA-family, PaLM, 친칠라, T5

왜 RMSNorm인가요?

현대적 설명 - 더 빠르고(똑같이 좋습니다). • 연산 감소 (평균 계산 없음) • 매개변수 감소 (저장할 편향 항 없음)

$$y = \frac{x - \mathbf{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

이 설명은 의미가 있나요?

Operator class	% flop
Δ Tensor contraction	99.80
$\square$ Stat. normalization	0.17
$\circ$ Element-wise	0.03


행렬 곱셈은 FLOP(및 메모리)의 대부분입니다 .

왜 RMSNorm인가 (2)

중요한 교훈: FLOPS는 런타임이 아닙니다! (나중에 더 자세히 설명하겠습니다)

Operator class	% flop	% Runtime
△ Tensor contraction	99.80	61.0
□ Stat. normalization	0.17	25.5
○ Element-wise	0.03	13.5

데이터 이동의 중요성으로 인해 RMSNorm
은 여전히 중요할 수 있습니다.



왼쪽 상단("43G")은 FLOPS입니다.

오른쪽 상단("153")은 FLOP 대 메모리 비율입니다.

RMSNorm - 검증

RMSNorm 런타임(그리고 놀랍게도 성능) 향상이 논문에서 확인되었습니다.

Model	Params	Ops	Step/s	Early loss	Final loss	SGLUE	XSum	WebQ	WMT EnDe
Vanilla Transformer	223M	11.1T	3.50	2.182 ± 0.005	1.838	71.66	17.78	23.02	26.62
RMS Norm	223M	11.1T	3.68	2.167 ± 0.008	1.821	75.45	17.94	24.07	27.14
Rezero	223M	11.1T	3.51	2.262 ± 0.003	1.939	61.69	15.64	20.90	26.37
Rezero + LayerNorm	223M	11.1T	3.26	2.223 ± 0.006	1.858	70.42	17.58	23.02	26.29
Rezero + RMS Norm	223M	11.1T	3.34	2.221 ± 0.009	1.875	70.33	17.32	23.02	26.19
Fixup	223M	11.1T	2.95	2.382 ± 0.012	2.067	58.56	14.42	23.02	26.31

나랑 등 2020

더 일반적으로: 편향 용어 삭제

대부분의 현대 변압기에는 바이어스 항목이 없습니다.

원래 변압기:

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

대부분의 구현(게이트되지 않은 경우):

$$\begin{pmatrix} x \\ 1 \end{pmatrix} = \begin{pmatrix} W_1 & b_1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ 1 \end{pmatrix}$$

이유: 메모리(RMSnorm과 유사) 및 최적화 안정성

LayerNorm: 요약

- 기본적으로 모든 사람이 사전 규범을 적용합니다.
 - 직관 - 잔여 연결의 좋은 부분 유지
 - 관찰 - 더 나은 기울기 전파, 스파이크 감소
 - 일부 사람들은 잔여 스트림 외부에 두 번째 규범을 추가합니다(사후 규범 아님)
- 대부분의 사람들은 RMSnorm을 사용합
 - 니다.
 - 실제로 LayerNorm만큼 잘 작동합니다.
 - 그러나 이동할 매개변수가 적기 때문에 벽시계 시간이 절약됩니다.
 - 사람들은 일반적으로 계산/매개변수 트레이드오프가 없기 때문에 편향 항목을 삭제합니다.
 - 엄청난.

활성화

다양한 활성화가 가능합니다 .


ReLU, GeLU, 스위시, ELU, GLU, GeGLU, ReGLU, SeLU, SwiGLU, LiGLU

이게 뭐예요? 사람들은 뭘 쓰죠? 중요한가요?

몇 가지 일반적인 활성화

재개하다

$$f(x) = \max(0, x)$$




주목할만한 모델:

원래 변압기, T5,
고퍼, 친칠라, OPT

깎다

$$f(x) = \text{GELU}(x) = \Phi(x) \cdot x$$



주목할만한 모델:

GPT1/2/3, GPTJ, GPT-Neox,
꽃

SwiGLU / GeGLU (다음 슬라이드..)

주목할만한 모델:

라마, PaLM, T5 v1.1, 대부분
2023년 이후 모델

게이트 활성화(*GLU)

GLU는 FF 레이어의 '첫 번째 부분'을 수정합니다.

$$(\quad) = \text{최대 } 0, (\quad_1)_2$$

선형 + ReLU 대신 위의 내용을 (항목별) 선형 항으로 확장합니다.

$$\text{최대 } \alpha, (\quad_1) \rightarrow \text{최대 } \alpha, (\quad_1) \otimes (\quad)$$

이는 게이트된 변형(ReGLU)을 제공합니다. 추가 매개변수(V)가 있다는 점에 유의하세요.

$$\text{FFReGLU} \in (\text{최대 } 0, (\quad_1) \otimes)_2$$

표준 FF 레이어의 게이트 변형

게글루

$$\text{FFN}_{\text{GEGLU}}(x, W, V, W_2) = (\text{GELU}(xW) \otimes xV)W_2$$

주목할만한 모델:

T5 v1.1, mT5, LaMDA, Phi3,
Gemma 2, Gemma 3

SwiGLU (swish는 시그모이드())

$$\text{FFN}_{\text{SwiGLU}}(x, W, V, W_2) = (\text{Swish}_1(xW) \otimes xV)W_2$$

주목할만한 모델:

라마 1/2/3, 팔름, 미스트랄,
O1Mo, 대부분 모델 2023년 이후 출시

참고: 게이트 모델은 더 작은 차수를 사용합니다.

2/3까지

게이트형 선형 유닛이 작동하니까?

네, 꽤 일관되게 그렇습니다.

	Score Average	CoLA MCC	SST-2 Acc
FFN _{ReLU}	83.80	51.32	94.04
FFN _{GELU}	83.86	53.48	94.04
FFN _{Swish}	83.60	49.79	93.69
FFN _{GLU}	84.20	49.16	94.27
FFN _{GEGLU}	84.12	53.65	93.92
FFN _{Bilinear}	83.79	51.02	94.38
FFN _{SwiGLU}	84.36	51.59	93.92
FFN _{ReGLU}	84.67	56.16	94.38
[Raffel et al., 2019]	83.28	53.84	92.68
ibid. stddev.	0.235	1.111	0.569

게이트형 선형 유닛이 작동합니까? (2)

예, Shazeer 2020을 뒷받침하는 다른 작업도 있습니다.

Model	Params	Ops	Step/s	Early loss	Final loss	SGLUE	XSum	WebQ
Vanilla Transformer	223M	11.1T	3.50	2.182 ± 0.005	1.838	71.66	17.78	23.02
GeLU	223M	11.1T	3.58	2.179 ± 0.003	1.838	75.79	17.86	25.13
Swish	223M	11.1T	3.62	2.186 ± 0.003	1.847	73.77	17.74	24.34
ELU	223M	11.1T	3.56	2.270 ± 0.007	1.932	67.83	16.73	23.02
GLU	223M	11.1T	3.59	2.174 ± 0.003	1.814	74.20	17.42	24.34
GeGLU	223M	11.1T	3.55	2.130 ± 0.006	1.792	75.96	18.27	24.87
ReGLU	223M	11.1T	3.57	2.145 ± 0.004	1.803	76.17	18.36	24.87
SeLU	223M	11.1T	3.55	2.315 ± 0.004	1.948	68.76	16.76	22.75
SwiGLU	223M	11.1T	3.53	2.127 ± 0.003	1.789	76.00	18.20	24.34
LiGLU	223M	11.1T	3.59	2.149 ± 0.005	1.798	75.34	17.97	24.34
Sigmoid	223M	11.1T	3.63	2.291 ± 0.019	1.867	74.31	17.51	23.02
Softplus	223M	11.1T	3.47	2.207 ± 0.011	1.850	72.45	17.65	24.34

나랑 등 2020

게이팅, 활성화


- 모델 전반에 걸쳐 다양한 변형(ReLU, GeLU, *GLU)이 있습니다.
- *GLU는 좋은 모델에 반드시 필요한 것은 아니지만 (GPT3 참조), 최근의 이상치 모델에는 도움이 될 수 있습니다.

Nemotron 340B(제공 ReLU), Falcon 2 11b(ReLU)

- 그러나 증거는 Swi/GeGLU에서 어느 정도 일관된 이득을 얻는다는 것을 가리킵니다.

직렬 계층과 병렬 계층

일반 변압기 블록은 직렬입니다. 즉, 주의력을 계산한 다음 MLP를 계산합니다.



변압기 블록을 병렬화할 수 있을까요?

병렬 레이어

일부 모델(GPTJ, PaLM, GPT-NeoX)은 병렬 레이어를 사용합니다. 원래는 GPT-J에 있었습니다.

Parallel Layers – We use a “parallel” formulation in each Transformer block ([Wang & Komatsuzaki, 2021](#)), rather than the standard “serialized” formulation. Specifically, the standard formulation can be written as:

$$y = x + \text{MLP}(\text{LayerNorm}(x + \text{Attention}(\text{LayerNorm}(x))))$$

Whereas the parallel formulation can be written as:

$$y = x + \text{MLP}(\text{LayerNorm}(x)) + \text{Attention}(\text{LayerNorm}(x))$$

The parallel formulation results in roughly 15% faster training speed at large scales, since the MLP and Attention input matrix multiplications can be fused. Ablation experiments showed a small quality degradation at 8B scale but no quality degradation at 62B scale, so we extrapolated that the effect of parallel layers should be quality neutral at the 540B scale.

올바르게 구현하면 LayerNorm을 공유할 수 있고 행렬 곱셈을 융합할 수 있습니다.

최신 모델: Cohere Command A, Falcon 2 11B, Command R+

요약: 아키텍처

사전 대 사후 규범: • 모든

사람이 사전 규범을 수행합니다(예외)
OPT350M), 아마도 그럴 만한 이유가 있을 것입니다.

레이어 대 RMSnorm:

- RMSnorm은 컴퓨팅 측면에서도 뚜렷한 우위를 보이며 때로는 성능 면에서도 우위를 보입니다.

게이팅:

- GLU는 일반적으로 더 나은 것으로 보이지만 차이는 작습니다.

직렬 계층과 병렬 계층:

- 매우 심각한 절제는 없지만 컴퓨터적으로는 승리합니다.

AI Name	# Year	Norm	Parallel Layer	Pre-norm	Position embedding	Activations
Original transformer	2017	LayerNorm	Serial	☐	Sine	ReLU
GPT	2018	LayerNorm	Serial	☐	Absolute	GeLU
T5 (11B)	2019	RMSNorm	Serial	☒	Relative	ReLU
GPT2	2019	LayerNorm	Serial	☒	Absolute	GeLU
T5 (XXL 11B) v1.1	2020	RMSNorm	Serial	☒	Relative	GeGLU
mT5	2020	RMSNorm	Serial	☒	Relative	GeGLU
GPT3 (175B)	2020	LayerNorm	Serial	☒	Absolute	GeLU
GPTJ	2021	LayerNorm	Parallel	☒	RoPE	GeLU
LaMDA	2021			☒	Relative	GeGLU
Anthropic LM (not claude)	2021			☒		
Gopher (280B)	2021	RMSNorm	Serial	☒	Relative	ReLU
GPT-NeoX	2022	LayerNorm	Parallel	☒	RoPE	GeLU
BLOOM (175B)	2022	LayerNorm	Serial	☒	Alibi	GeLU
OPT (175B)	2022	LayerNorm	Serial	☒	Absolute	ReLU
PaLM (540B)	2022	RMSNorm	Parallel	☒	RoPE	SwiGLU
Chinchilla	2022	RMSNorm	Serial	☒	Relative	ReLU
Mistral (7B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
LLaMA2 (70B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
LLaMA (65B)	2023	RMSNorm	Serial	☒	RoPE	SwiGLU
GPT4	2023			☐		
BaiChuan 2	2023	RMSNorm	Serial	☒	Alibi	SwiGLU
Olmo 2	2024	RMSNorm	Serial	☐	RoPE	SwiGLU
Gemma 2 (27B)	2024	RMSNorm	Serial	☒	RoPE	GeGLU
Nemotron-4 (340B)	2024	LayerNorm	Serial	☒	RoPE	SigRelu
Qwen 2 (72b) - same for 2.5	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Falcon 2 11B	2024	LayerNorm	Parallel	☒	RoPE	GeLU
Phi3 (small) - same for phi4	2024	RMSNorm	Serial	☒	RoPE	GeGLU
Llama 3 (70B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Reka Flash	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Command R+	2024	LayerNorm	Parallel	☒	RoPE	SwiGLU
OLMo	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Qwen (14B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
DeepSeek (67B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Yi (34B)	2024	RMSNorm	Serial	☒	RoPE	SwiGLU
Mixtral of Experts	2024			☐		
Command A	2025	LayerNorm	Parallel	☒	Hybrid (RoPE+NoPE)	SwiGLU
Gemma 3	2025	RMSNorm	Serial	☐	RoPE	GeGLU
SmoLLM2 (1.7B)	2025	RMSNorm	Serial	☒	RoPE	SwiGLU

위치 임베딩의 다양한 변형

사인 임베딩: 로컬라이제이션을 가능하게 하는 사인과 코사인을 추가합니다.

$$(\ , \) = +$$

$$\begin{aligned} PE_{(pos, 2i)} &= \sin(pos/10000^{2i/d_{\text{model}}}) \\ PE_{(pos, 2i+1)} &= \cos(pos/10000^{2i/d_{\text{model}}}) \end{aligned}$$

주목할만한 모델:

원래 변압기

절대 임베딩: 임베딩에 위치 벡터 추가

$$(\ , \) = +$$

주목할만한 모델:

GPT1/2/3, OPT

상대적 임베딩: 주의 계산에 벡터 추가

$$e_{ij} = \frac{x_i W^Q (x_j W^K + a_{ij}^K)^T}{\sqrt{d_z}}$$

주목할만한 모델:

T5, 고퍼, 친칠라

로프 매핑 (다음 슬라이드..)

주목할만한 모델:

GPTJ, PaLM, LLaMA
대부분의 2024년 이상 모델

RoPE: 회전 위치 임베딩

높은 수준의 사고 과정: 상대적 위치 임베딩은 어떤 (,) st이어야 합니다 .

$$\langle (,), (,) \rangle = (, ,)$$

즉, 어텐션 함수는 상대 위치(ij)에만 의존하게 됩니다. 기존 임베딩은 왜 이 목표를 달성하지 못하는 걸까요 ?

- 사인: 상대적이지 않은 다양한 교차항이 있습니다.

$$\langle (,), (,) \rangle = \langle , \rangle + \langle , \dots \rangle$$


- 절대적: 분명히 상대적이지 않음

- 상대적 임베딩:


$$e_{ij} = \frac{x_i W^Q (x_j W^K + a_{ij}^K)^T}{\sqrt{d_z}} \quad \text{내적이 아니다}$$

RoPE: 회전 위치 임베딩

- 이 문제를 어떻게 해결할 수 있습니까? • 우리
- 는 임베딩이 절대 위치에 따라 변하지 않기를 원합니다.
- 우리는 내적이 임의의 회전에 대해 불변하다는 것을 알고 있습니다.




위치 독립 임베딩



"우리는 그것을
알고 있습니다" 를 내장

'0 위치'로 회전하고 '1 위치'로 회전합니다.




물론 알고 있
죠"라는 문구를 삽입

'2 위치'만큼 회전합니다.
'3 위치'로 회전합니다

RoPE: 회전 위치 임베딩

여러 가지 회전 방식이 있는데, 어떤 것을 선택해야 할까요?



[Su et al 2021]

좌표를 짝지어 2차원으로 회전시키면 됩니다(동기: 복소수)

실제 RoPE 수학

사인과 코사인을 곱합니다

$$f_{\{q,k\}}(\mathbf{x}_m, m) = \mathbf{R}_{\Theta, m}^d \mathbf{W}_{\{q,k\}} \mathbf{x}_m \quad (14)$$

$$\mathbf{R}_{\Theta, m}^d = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{pmatrix} \quad (15)$$

사인 임베딩과의 차이점 - 덧셈적이지 않음, 교차항 없음

RoPE 구현 및 코드

평소 주
의 사항

RoPE를 받으세요

행렬 cos/sin

쿼리/키
입력 곱하기

```
query_states = self.q_proj(hidden_states)
key_states = self.k_proj(hidden_states)
value_states = self.v_proj(hidden_states)

# Flash attention requires the input to have the shape
# batch_size x seq_length x head_dim x hidden_dim
# therefore we just need to keep the original shape
query_states = query_states.view(bsz, q_len, self.num_heads, self.head_dim).transpose(1, 2)
key_states = key_states.view(bsz, q_len, self.num_key_value_heads, self.head_dim).transpose(1, 2)
value_states = value_states.view(bsz, q_len, self.num_key_value_heads, self.head_dim).transpose(1, 2)

cos, sin = self.rotary_emb(value_states, position_ids)
query_states, key_states = apply_rotary_pos_emb(query_states, key_states, cos, sin)
```

...

아래의 일반적인 멀티 헤드 셀프 어텐션과 동일한 내용입니다.

참고: 위치 불변성을 강화하기 위해 각 주의 작업 에 임베딩

하이퍼파라미터

224n에서 궁금했을 만한 변압기 하이퍼파라미터 관련 질문..

- 피드포워드 크기는 숨겨진 크기에 비해 얼마나 커야 합니까?
- 헤드는 몇 개이고, num_heads는 항상 숨겨진 크기를 나누어야 합니까?
- 어휘 크기는 어떻게 해야 합니까?

그리고 다른 모델 설정 질문 • 사람들이
이 거대한 LM을 정규화할까요? • 사람들은 이 모델을 어떻게 확장할까요? 매우 깊거나 매우 넓게요?

놀라운 (?) 합성 하이퍼파라미터 1

피드포워드 - 모델 차원 비율.

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

관련성이 있는 두 가지 차원이 있습니다. 피드포워드 딥() 및 모델 dim
(). 그들의 관계는 어떻게 되어야 할까요?

=

이는 거의 항상 사실입니다. 몇 가지 예외가 있긴 합니다.

예외 #1 – GLU 변형

GLU 변종은 $2/3$ 로 축소된다는 점을 기억하세요. 즉, 대부분의 GLU 변종은 $2/3$ 를 가지고 있다는 뜻입니다. 이는 대부분 일
 $= \frac{8}{3}$ 어나는 일입니다. 주목할 만한 몇 가지 예가 있습니다.

모델	/
손바닥 안에 감추다	4
미스트랄 7B	3.5
LLaMA-2 70B	3.5
70B에 전화하세요	2.68
퀀 14B	2.67
딥시크 67B	2.68
34B를 하세요	2.85
T5 v1.1	2.5

모델은 대략 이 범위에 있지만 PaLM, LLaMA2 및 Mistral은 약간 더 큼니다.

예외 #2 – T5

우리가 이미 보았고 앞으로도 볼 수 있듯이, 대부분의 LM은 지루하고 보수적인 하이퍼 매개변수를 가지고 있습니다. 예외 중 하나는 매우 대담한 설정을 갖춘 T5[Raffel et al 2020]입니다 .

특히 11B 모델의 경우,

$$\begin{aligned} &= 65,536 \\ &= 1024 \end{aligned}$$


놀랍게도 64배의 배수입니다.

for “11B” we use $d_{\text{ff}} = 65,536$ with 128-headed attention producing a model with about 11 billion parameters. We chose to scale up d_{ff} specifically because modern accelerators (such as the TPUs we train our models on) are most efficient for large dense matrix multiplications like those in the Transformer’s feed-forward networks.

기타 최근 예외 – Gemma 2(8x), SmolLM/Gemma 3(4x, GLU)

왜 이런 배수 범위를 사용했나요?

경험적으로 이 하이퍼매개변수가 거의 최적의 되는 1~10 사이의 분지가 있습니다.



모델 차원 하이퍼매개변수에서 무엇을 배울 수 있나요?

- '기본' 선택 = 4
모든 현대 LLM.
그리고 = 2.66
거의 잘 작동했습니다
- 하지만 T5는 64개의 하이퍼매개변수 선택에 있어서 급진적인 선택조차도 확정적이지 않다는 것을 보여줍니다.
작동할 수 있습니다.
- 즉, T5에는 '개선된' 후속 모델(T5 v1.1)이 있으며 GeGLU에서 훨씬 더 표준적인 2.5 배수를 사용하므로 64배 배수는 최적이지 아닐 가능성이 높습니다.

놀라운 (?) 합 of 하이퍼파라미터 2

헤드-디밍*헤드 수 대 모델-디밍 비율. 참고로, 224n에서 슬라이드하세요.

Multi-head self-attention is computationally efficient

- Even though we compute h many attention heads, it's not really more costly.
 - We compute $XQ \in \mathbb{R}^{n \times d}$, and then reshape to $\mathbb{R}^{n \times h \times d/h}$. (Likewise for XK , XV .)
 - Then we transpose to $\mathbb{R}^{h \times n \times d/h}$; now the head axis is like a batch axis.
 - Almost everything else is identical, and the **matrices are the same sizes**.

반드시 그럴 필요는 없습니다. head-dimensions > model-dim / num-heads일 수도 있습니다.

하지만 대부분의 모델은 이 지침을 따릅니다.

머리가 몇 개이고, 모델은 뭐예요?


이 하이퍼매개변수의 몇 가지 예

	헤드 수	헤드 간격	모델 간격 비율	
GPT3	96	128	12288	1
T5	128	128	1024	16
T5 v1.1	64	64	4096	1
라엠다	128	128	8192	2
손바닥 안에 감추다	48	258	18432	1.48
LLaMA2	64	128	8192	1

대부분 모델의 비율은 1 정도입니다. 하지만 일부 Google 모델은 주목할 만한 예외를 보입니다.

1:1 비율에 대한 증거?

1-1 비율에 반대하는 논문이 작성되었습니다. [Bhojanapalli et al 2020]



하지만 실제로는 심각한 '낮은 순위 병목 현상'이 나타나지 않는 것 같습니다.

종횡비

모델을 깊게 해야 할까요, 넓게 해야 할까요? 얼마나 깊고 얼마나 넓게 해야 할까요?

대부분의 모델은 이 부분에서도 놀라울 정도로 일관성을 보입니다!

최적의 장소는?


모델	/
꽃	205
T5 v1.1	171
팔름(540B)	156
GPT3/OPT/미스트랄/퀵 128	
전화 / 전화2 / 친칠라	102
T5(11B)	43
GPT2	33

종횡비에 대한 고려 사항


매우 깊은 모델은 병렬화가 더 어렵고 대기 시간이 더 길습니다.

The Limits of Depth vs Width We note an obvious limitation with our advice. Scaling depth has an obvious limiter, i.e., they are non-parallelizable across different machines or devices and every computation has to always wait for the previous layer. This is unlike width, which can be easily parallelizable over thousands or hundreds of thousands of devices. Within the limitation of scaling


[Tay et al 2021]



종횡비 스케일링에 대한 증거



[Kaplan et al 2020]



[Tay et al 2021]

일반적인 어휘 규모는 어느 정도입니까?

단일 언어 모델 - 30-50k 어휘

모델	토큰 수
원래 변압기	37000
GPT	40257
GPT2/3	50257
T5/T5v1.1	32128
전화	32000

다국어/생산 시스템 100-250k

모델	토큰 수
엠티5	250000
손바닥 안에 감추다	256000
GPT4	100276
명령 A	255000
답시크	100000
퀵 15B	152064
하다	64000

단일 언어 어휘는 엄청날 필요는 없지만 다국어 어휘는 엄청날 필요가 있습니다.

드롭아웃 및 기타 정규화

사전 학습 중에 정규화가 필요합니까?

반대 의견: • 매개변수보다

훨씬 많은 데이터(수조 개의 토큰)가 있습니다. • SGD는 코퍼스에 대해 단 한 번의 패스만 수행합니다(기억하기 어려움).

이건 다 꽤 합리적인 생각이에요.. 하지만 사람들은 실제로 어떻게 할까요?

실제에서의 드롭아웃과 체중 감소

모델	드롭아웃* 체중 감소	
원래 변압기 0.1		0
GPT2	0.1	0.1
E5	0.1	0
GPT3	0.1	0.1
T5 v1.1	0	0
순배치 안에 감추다	0	(변하기 쉬운)
고르다	0.1	0.1
전화	0	0.1
퀵 14B	0.1	0.1


많은 이전 모델은 사전 학습
중에 드롭아웃을 사용했습니다.

최신 모델(Qwen 제외)은 무게 감소에만
의존합니다.


* 대부분의 논문에서는 탈락에 대해 전혀 다루지 않습니다. 개방형 모델에서는 탈락을 다루지 않는 것과 매우 유사합니다.
이는 폐쇄형 모델에서는 사실이 아닐 수 있습니다.

왜 체중 감소 LLM인가요?


[Andriushchenko et al 2023]은 LLM 체중 감소에 대한 흥미로운 관찰 결과를 가지고 있습니다.



과잉적합을 제어하는 것이 아닙니다



가중치 감소는 학습률(코사인 일정)과 상호 작용합니다.



요약: 하이퍼파라미터

피드포워드

- 4의 법칙(GLU의 경우 8/3)이 표준입니다(일부 증거 있음)

머리가 어두워지다

- 헤드 댄*헤드 수 = D 모델은 표준이지만 검증이 거의 없음

종횡비

- '좋은' 값의 범위가 넓습니다(100-200).
시스템 문제는 가치를 결정합니다.


정규화

- 여전히 LM을 '정규화'하지만 그 효과는 주로 최적화 역학에 있습니다.

As Name	# Year	# MLP factor	Aspect ratio (dlayer)	# weight decay	# drop_rate
Original transformer	2017	4	85	0	0.1
GPT	2018	4	64	0.1	0.1
TS (11B)	2019	64	43	0	0.1
GPT2	2019	4	33	0.1	0.1
TS (XXL 11B) v1.1	2020	2.5	171	0	0
mT5	2020	2.5	171	0	0
GPT3 (175B)	2020	4	128	0.1	0.1
GPTJ	2021		146	0.1	0
LaMDA	2021	8	128		
Anthropic LM (not claude)	2021	4	128		
Gopher (280B)	2021	4	205		
GPT-NeoX	2022	4	140	0.01	0
BLOOM (175B)	2022	4	205	0.1	0
OPT (175B)	2022	4	128	0.1	0.1
PaLM (540B)	2022	4	156		0
Chinchilla	2022	4	102		
BaiChuan 2	2023	2.88	128	0.1	0
Mistral (7B)	2023	3.5	128	0.1	0
LLaMA2 (70B)	2023	3.5	102	0.1	0
LLaMA (65B)	2023	2.6875	102	0.1	0
GPT4	2023		0		
Orino 2	2024	2.6875	128		
Gemma 2 (27B)	2024	8	100		
Nemotron-4 (340B)	2024	4	192		0
Qwen 2 (72b) - same for 2.5	2024	3.609	102		
Falcon 2 11B	2024	4	68	0.1	
Phi3 (small) - same for phi4	2024	3.5	128		
Llama 3 (70B)	2024	3.5	102		0
Reka Flash	2024		0		
Command R+	2024	2.75	192		
OLMo	2024	2.6875	128	0.1	0
Qwen (14B)	2024	2.675	128	0.1	0.1
DeepSeek (67B)	2024	2.6875	86	0.1	0
Yi (34B)	2024	2.857142	119	0.1	0
Mistral of Experts	2024		0		
Command A	2025		0		
Gemma 3	2025	4	87		
SmolLM2 (1.7B)	2025	4	85		

안정성 트릭



최근에는 안정적인 훈련에 많은 관심이 집중되고 있습니다.



파란색 곡선처럼 보이는 모델을 훈련하지 마세요!

문제는 어디에서 발생하나요? 소프트맥스를 조심하세요!

소프트맥스 - 지수/0으로 나누기 때문에 제대로 작동하지 않을 수 있습니다.



출력 소프트맥스 안정성 - 'z-손실'

소프트맥스 계산을 회상해보세요

$$\begin{aligned}\log(P(x)) &= \log\left(\frac{e^{U_r(x)}}{Z(x)}\right) \\ &= U_r(x) - \log(Z(x)) \\ Z(x) &= \sum_{r'=1}^{|V|} e^{U_{r'}(x)}\end{aligned}$$

$$\begin{aligned}L &= \sum_i [\log(P(x_i)) - \alpha(\log(Z(x_i)) - 0)^2] \\ &= \sum_i [\log(P(x_i)) - \alpha \log^2(Z(x_i))]\end{aligned}$$


[Devlin 2014에서 발췌]

안정성에 유용하죠! PaLM은 이 'z 손실' 기법을 처음 개발했습니다.

We additionally use an auxiliary loss of $z_loss = 10^{-4} \cdot \log^2 Z$ to encourage the softmax normalizer $\log(Z)$ to be close to 0, which we found increases the stability of training.

기타 사례: 바이찬 2호(2023), DCLM(2024), OLMo 2(2025)

주의 소프트맥스 안정성 - 'QK 규범'



소프트맥스 연산에 들어가기 전에 쿼리와 키는 레이어(RMS) 정규화됩니다.

다른 예: DCLM, OLMo2, Gemma 2

원래 비전 및 다중 모드 모델에서 유래[Dehgani 2023, Idefcs, Chameleon]

로짓 소프트 캡핑.

Tanh를 통해 로짓을 최대값으로 소프트 캡핑

Logit soft-capping. We cap logits ([Bello et al., 2016](#)) in each attention layer and the final layer such that the value of the logits stays between $-\text{soft_cap}$ and $+\text{soft_cap}$. More specifically, we cap the logits with the following function:

$$\text{logits} \leftarrow \text{soft_cap} * \tanh(\text{logits}/\text{soft_cap}).$$

We set the `soft_cap` parameter to 50.0 for the self-attention layers and to 30.0 for the final layer.

로짓이 터지는 것을 방지하지만, 성능 문제가 발생할 수도 있나요?

Table 4: Models perplexity with confidence interval ± 0.1 at 95% level.

bf16 baseline	<i>soft_cap</i>	<i>QKV_norm</i>	<i>QK_norm_cap</i>	<i>QK_norm</i>	<i>QK_FC_norm</i>
11.19	11.24	10.85	11.00	10.84	10.87

주의 머리

대부분의 모델은 몇 가지 사소한 예외를 제외하면 전혀 주목을 끌지 않습니다.


GQA / MQA : 헤드 수를 줄여 추론 비용 절감

희소 또는 슬라이딩 윈도우 주의(GPT4/Mistral): 컴퓨팅 비용을 줄이기 위해 주의 패턴 제한

이국적인 SSM 콘텐츠(잠바, 팔콘 3 등): 다루지 않음(죄송합니다!)

GQA/MQA – 주의 집중 비용 감소

주의에 관련된 계산에 대해 생각해 보자



총 산술 연산 ($\frac{1}{2}n^3$), 총 메모리 액세스 ($\frac{1}{2}n^3 + \frac{1}{2}n^2$)


산술 강도가 높습니다 $\left(\left(\frac{1}{2} + \frac{1}{2} \right)^{-1} \right)$ - 우리는 GPU를 계속 실행할 수 있습니다

GQA/MQA – 주의 집중 비용 감소

텍스트를 생성할 때 증분적 경우는 어떨습니까?

주요 차이점: 생성 프로세스를 병렬화할 수 없음 - 단계별로 진행해야 함

이 경우 - 'KV 캐시'를 통해 주의력을 점진적으로 재계산/업데이트해야 합니다.



GQA/MQA – 주의 집중 비용 감소

충분 산술 강도는 무엇입니까?


총 산술 연산 ($\frac{n^2}{d}$), 총 메모리 액세스 ($\frac{n^2}{d} + \frac{n^2}{d}$)

산술 강도가 좋지 않습니다 $\left(\left(- + \frac{1}{d} \right)^{-1} \right)$ - 대량 배치 필요 + 짧은 seq 길이
(n) 또는 큰 모델 차수 (d)

이 문제를 해결할 방법이 있을까요? n/d 항은 약분하기 어렵습니다.

MQA – 주요 차원이 더 적습니다.

핵심 아이디어 - 여러 개의 쿼리를 가지지만 키와 값에 대한 차원은 하나만 있습니다.




메모리(KV 캐시)에서 이동하거나 제거해야 할 항목이 훨씬 적습니다.

총 메모리 액세스 ($2 + 2$), 산술 강도 $\left(\left(\frac{1}{2} + \frac{1}{2} + \frac{1}{2} \right)^{-1} \right)$

최근 확장 - GQA

KV의 한 차원까지 가지 마세요. dim을 줄이세요.



표현력(키-쿼리 비율)과 추론 효율성을 제어하는 간단한 노브



MQA가 아프나요? 가끔은요..

MQA로 소규모 PPL 히트 [Shazeer 2019]

Table 3: Billion-Word LM Benchmark Results.

Attention	h	d_k, d_v	d_{ff}	dev-PPL
multi-head	8	128	8192	29.9
multi-query	8	128	9088	30.2
multi-head	1	128	9984	31.2
multi-head	2	64	9984	31.1
multi-head	4	32	9984	31.0
multi-head	8	16	9984	30.9



GQA에 대한 적응률 낮음/적응률 없음 [Ainslie 2023]





희소/슬라이딩 윈도우 주의

전체 맥락을 살펴보는 것은 비용이 많이 들 수 있습니다(2차).



표현력과 런타임 간의 균형을 맞추는 희소/구조화된 주의 구축(GPT3)



(a) Transformer




(b) Sparse Transformer (strided)



(c) Sparse Transformer (fixed)

슬라이딩 윈도우 주의


이 아이디어의 또 다른 변형 - 슬라이딩 윈도우 주의



Vanilla Attention



Sliding Window Attention




Effective Context Length

스트라이드 패턴의 주요 부분만 사용하세요. 깊이를 효과적인 컨텍스트로 확장하세요(미스트랄)

현재 표준 트릭 – '전체' 및 'LR' 주의 삽입

Cohere Command A에서 – 4번째 레이어마다 전체 주의가 필요합니다.



NoPE를 통한 장거리 정보, RoPE + SWA를 통한 단거리 정보.

다른 모델 – LLaMA 4, Gemma는 SWA+Full RoPE를 수행합니다.

요약, 결론 등

변압기의 많은 측면(아치, hparams)은 대형 LM에서 공통적입니다.

As Name	Has pa...	Link	# Year	Tokenizer type	# Vocab count	Norm	Parallel Layer	Pre-norm	Position embedding	Activations	MoE	# MLP factor	# num_layers	# model_dim
Original transformer	Yes	arxiv.org/abs...03762	2017	BPE	37000	LayerNorm	Serial	☐	Sine	ReLU	☐	4	6	
GPT	Yes	cdn.openai.com/res...er.pdf	2018	BPE	40257	LayerNorm	Serial	☐	Absolute	GeLU	☐	4	12	
GPT2	Yes	cdn.openai.com/bet...rk.pdf	2019	BPE	50257	LayerNorm	Serial	☐	Sine	GeLU	☐	4	48	
T5 (11B)	Yes	arxiv.org/abs...10683	2019	SentencePiece	32128	RMSNorm	Serial	☒	Relative	ReLU	☐	64	24	
GPT3 (175B)	Yes	arxiv.org/abs...14165	2020	BPE	50257	LayerNorm	Serial	☒	Sine	GeLU	☐	4	96	
mT5	Yes	arxiv.org/abs...11934	2020	SentencePiece	250000	RMSNorm	Serial	☒	Relative	GeGLU	☐	2.5	24	
T5 (XXL 11B) v1.1	Kind of	github.com/go...d#1511	2020	SentencePiece	32128	RMSNorm	Serial	☒	Relative	GeGLU	☐	2.5	24	
Gopher (280B)	Yes	arxiv.org/abs...11446	2021	SentencePiece	32000	RMSNorm	Serial	☒	Relative	ReLU	☐	4	80	
Anthropic LM (not claude)	Yes	arxiv.org/abs...00861	2021	BPE	65536			☒			☐	4	64	
LaMDA	Yes	arxiv.org/abs...08239	2021	BPE	32000			☒	Relative	GeGLU	☐	8	64	
GPTJ	Kind of	huggingface.co/Ele...t-j-6b	2021	BPE	50257	LayerNorm	Parallel	☒	RoPE	GeLU	☐		28	
Chinchilla	Yes	arxiv.org/abs...15556	2022	SentencePiece	32000	RMSNorm	Serial	☒	Relative	ReLU	☐	4	80	
PaLM (540B)	Yes	arxiv.org/abs...02311	2022	SentencePiece	256000	RMSNorm	Parallel	☒	RoPE	SwiGLU	☐	4	118	
OPT (175B)	Yes	arxiv.org/abs...01068	2022	BPE	50272	LayerNorm	Serial	☒	Absolute	ReLU	☐	4	96	
BLOOM (175B)	Yes	arxiv.org/abs...05100	2022	BPE	250680	LayerNorm	Serial	☒	Alibi	GeLU	☐	4	70	
GPT-NeoX	Yes	arxiv.org/pdf...45.pdf	2022	BPE	50257	LayerNorm	Parallel	☒	RoPE	GeLU	☐	4	44	
GPT4 	Ad	arxiv.org/abs...08774	2023	BPE	100000			☐			☐			
LLaMA (65B)	Yes	arxiv.org/abs...13971	2023	BPE	32000	RMSNorm	Serial	☒	RoPE	SwiGLU	☐	2.6875	80	
LLaMA2 (70B)	Yes	arxiv.org/abs...09288	2023	BPE	32000	RMSNorm	Serial	☒	RoPE	SwiGLU	☐	3.5	80	
Mistral (7B)	Yes	arxiv.org/abs...06825	2023	BPE	32000	RMSNorm	Serial	☒	RoPE	SwiGLU	☐	3.5	32	

주요 차이점은? 위치 임베딩, 활성화, 토큰화